Clustering

Тема 4.1: кластеризация
Трек: beginners

Фирсанова В.И.

НИУ ВШЭ

Определение задачи кластеризации

Задача

Как и в **классификации**, присваивать класс каждому элементу набора данных

sample	class
sport	1
football	1
space	0
Moon	0
finance	3
election	2

Что демонстрирует таблица?

Чем кластеризация отличается от классификации

Вспомним

К каким типам обучения относят задачи **классификации** и **кластеризации**?

Класс, присваиваемый алгоритмом кластеризации, выводится из входных переменных и не является выходной переменной

https://web.stanford.edu/class/stats305c/lectures/Clustering.html

Кластеризация как задача обучения без учителя

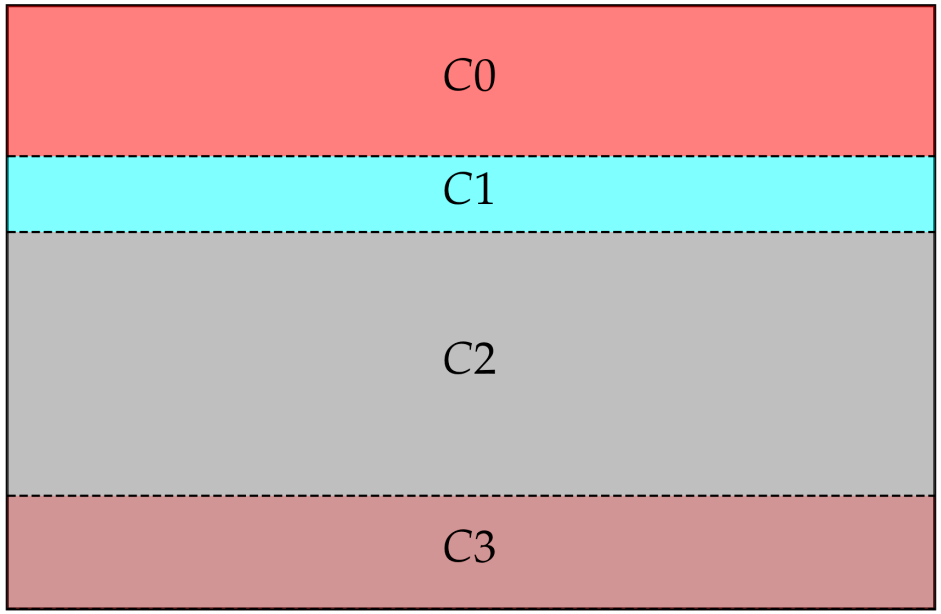

Рис.: The goal is to find homogeneous subgroups among the observations

Гомогенность

В статистике, **гомогенность** — характеристика данных, связанная с предположением о том, что наблюдения (observations) в выборке являются однородными по некоторому набору параметров.

https://wiki.loginom.ru/

Подходы к кластеризации

1. Прототипные методы (centroid-based)
2. Иерархические методы
3. Методы на основе анализа плотности распределения

и другие, см. *"Cluster Analysis" (Everitt et al.)*

Прототипные методы

- Один из самых популярных методов кластеризации
- Прототипные методы кластеризации, или **центроидные (centroid-based)**, представляют кластеры через центральные точки — **центроиды**, которые представляют средние точки каждого кластера

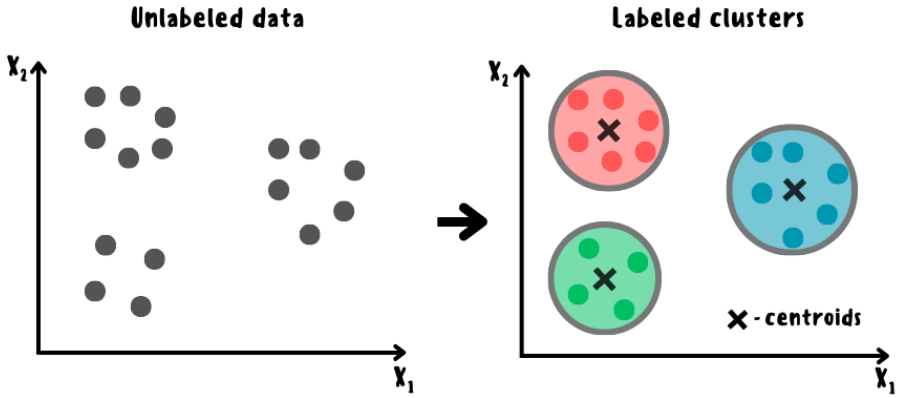

Рис.: Интуитивный пример

Математические основы кластеризации

Пусть $X = \{x^1, x^2, ..., x^N\}$ — множество N объектов, заданных в n-мерном векторном пространстве признаков:

$$x^k = (x_1^k, x_2^k, ..., x_n^k)^T, \quad k = \overline{1, N}.$$

Пусть $Y = \{1, 2, 3, ...\}$ — множество номеров (меток) кластеров

Важно

Мы **не задаём** эти метки вручную. Мы обучаем алгоритм, результатом работы которого будет отображение каждого объекта x^k в один из этих номеров.

Замечание по нотации: линия над 1, N означает "все целые числа от 1 до N включительно"

Формальная постановка задачи кластеризации

Мы допускаем, что между объектами существует отношение близости, которое можно количественно выразить через метрику (функцию расстояния) $p(x, x')$

Чаще всего используется евклидова метрика:

$$p_2(x, x') = \sqrt{\sum_{j=1}^{n} (x_j - x'_j)^2}$$

Эта идея лежит в основе множества алгоритмов кластеризации: мы вычисляем расстояние между элементами векторного пространства и группируем объекты в кластеры на основе их взаимной близости.

Алгоритм кластеризации

Цель: разбить конечную выборку объектов X на K непересекающихся подмножеств

$$S_k, \quad k = \overline{1, K}; \qquad X = \bigcup_{k=1}^{K} S_k,$$

называемых кластерами, так чтобы каждый кластер состоял из объектов, близких по метрике ρ, а объекты разных кластеров существенно отличались.

Алгоритм кластеризации — это функция $X \to Y$, которая каждому объекту $x \in X$ ставит в соответствие номер (метку) кластера $y \in Y$, где $Y = \{1, 2, \ldots, K\}$ — множество анонимных идентификаторов кластеров.

Дополнение к формуле

$$S_k, \quad k = \overline{1, K}; \qquad X = \bigcup_{k=1}^{K} S_k$$

- S_k — k-й кластер (подмножество объектов)
- $k = \overline{1, K}$ — k принимает все целые значения от 1 до K включительно
- X — исходное множество всех объектов
- $\bigcup_{k=1}^{K} S_k$ — объединение всех кластеров от S_1 до S_K

Формальная запись разбиения на кластеры

$$S_i \cap S_j = \varnothing \quad \text{для всех } i \neq j$$

$$\begin{cases} X = \bigcup_{k=1}^{K} S_k & \text{(покрытие — все объекты попали в кластеры)} \\ S_i \cap S_j = \varnothing,\ i \neq j & \text{(непересекаемость — объект только в одном класте} \\ S_k \neq \varnothing,\ k = \overline{1, K} & \text{(непустые кластеры, если } K \text{ задано заранее)} \end{cases}$$

Пример

Пусть $X = \{A, B, C, D\}$ и $K = 2$.

Возможное разбиение:

- $S_1 = \{A, B\}$
- $S_2 = \{C, D\}$

Проверяем:

- $S_1 \cup S_2 = \{A, B, C, D\} = X$
- $S_1 \cap S_2 = \varnothing$

Такая запись означает, что алгоритм кластеризации должен **разбить** X на K непересекающихся подмножеств, которые вместе покрывают все данные.

K-means clustering

- Число кластеров K фиксируется при использовании алгоритма
- Однако подобрать оптимальное число K — это задача машинного обучения

Цель метода — минимизировать внутрикластерную дисперсию:

$$\min_{C_1,\ldots,C_K} \sum_{\ell=1}^{K} W(C_\ell), \quad W(C_\ell) = \frac{1}{|C_\ell|} \sum_{i,j \in C_\ell} \text{Distance}^2(x_{i,:}, x_{j,:})$$

Влияние количества кластеров

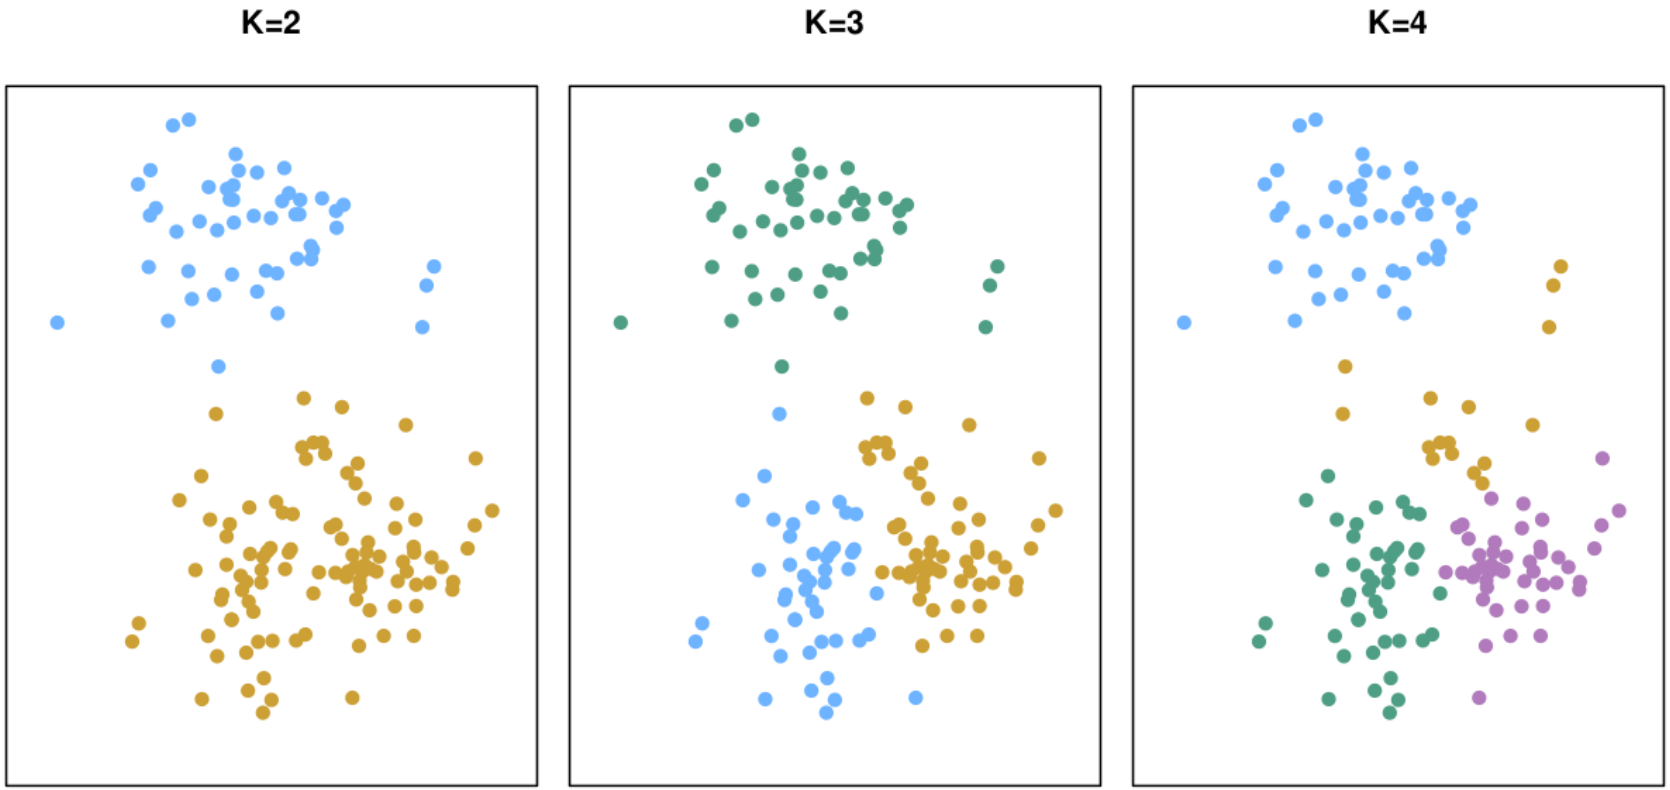

Уточнение формулы K-means

$$\min_{C_1,\ldots,C_K} \sum_{\ell=1}^{K} W(C_\ell), \quad W(C_\ell) = \frac{1}{|C_\ell|} \sum_{i,j \in C_\ell} \|x_{i,:} - x_{j,:}\|^2$$

- C_ℓ — кластер с номером ℓ
- $|C_\ell|$ — количество объектов в кластере ℓ
- $x_{i,:}$ — i-й объект (вектор признаков)
- $\|x_{i,:} - x_{j,:}\|^2$ — квадрат евклидова расстояния между объектами i и j

Дисперсия — мера разброса объектов внутри кластера.
$W(C_\ell)$ — среднее попарных квадратов расстояний между всеми объектами внутри кластера ℓ.
Суммируя $W(C_\ell)$ по всем кластерам и минимизируя эту сумму, мы добиваемся, чтобы объекты внутри каждого кластера были максимально близки друг к другу.

Как найти центроид

Центроидом кластера S_k называется геометрический центр точек k-го кластера в евклидовом пространстве:

$$X_k = \frac{1}{|S_k|} \sum_{x^i \in S_k} x^i,$$

где $|S_k|$ – число точек в k-ом кластере, $k = \overline{1, K}$; K – число кластеров.

Центроид служит *прототипом* кластера для оценки расстояний до новых точек при использовании уже обученного алгоритма; т.е. новый объект попадёт в класс на основании подсчета расстояний до ближайшего центроида.

Инициализация K-means

Шаг 1: присвоить каждой выборке произвольный номер кластера от 1 до K

Существуют разные методы инициализации кластеров:

1. **Случайная инициализация**: приводит к локальным минимумам
2. **K-means++**:
   - Выбирает один случайный центроид
   - Находит наиболее удалённый от него центроид по $D(x)$
   - Выбирает следующий центроид случайно с вероятностью, пропорциональной $D(x)^2$
   - Повторяет, пока не выбрано K центроидов

Шаг 2: 2 итеративных шага

Повторяем, пока кластеризация не станет постоянной:

1. Найти **центроид** каждого кластера C_i; то есть среднее всех выборок в кластере:

$$\bar{x}_{i,j} = \frac{1}{|C_i|} \sum_{x \in C_i} x_j \quad \text{для } j = 1, \ldots, p,$$

   где x_j — j-я координата вектора x
2. Переприсвоить каждую выборку ближайшему центроиду

Итеративный процесс

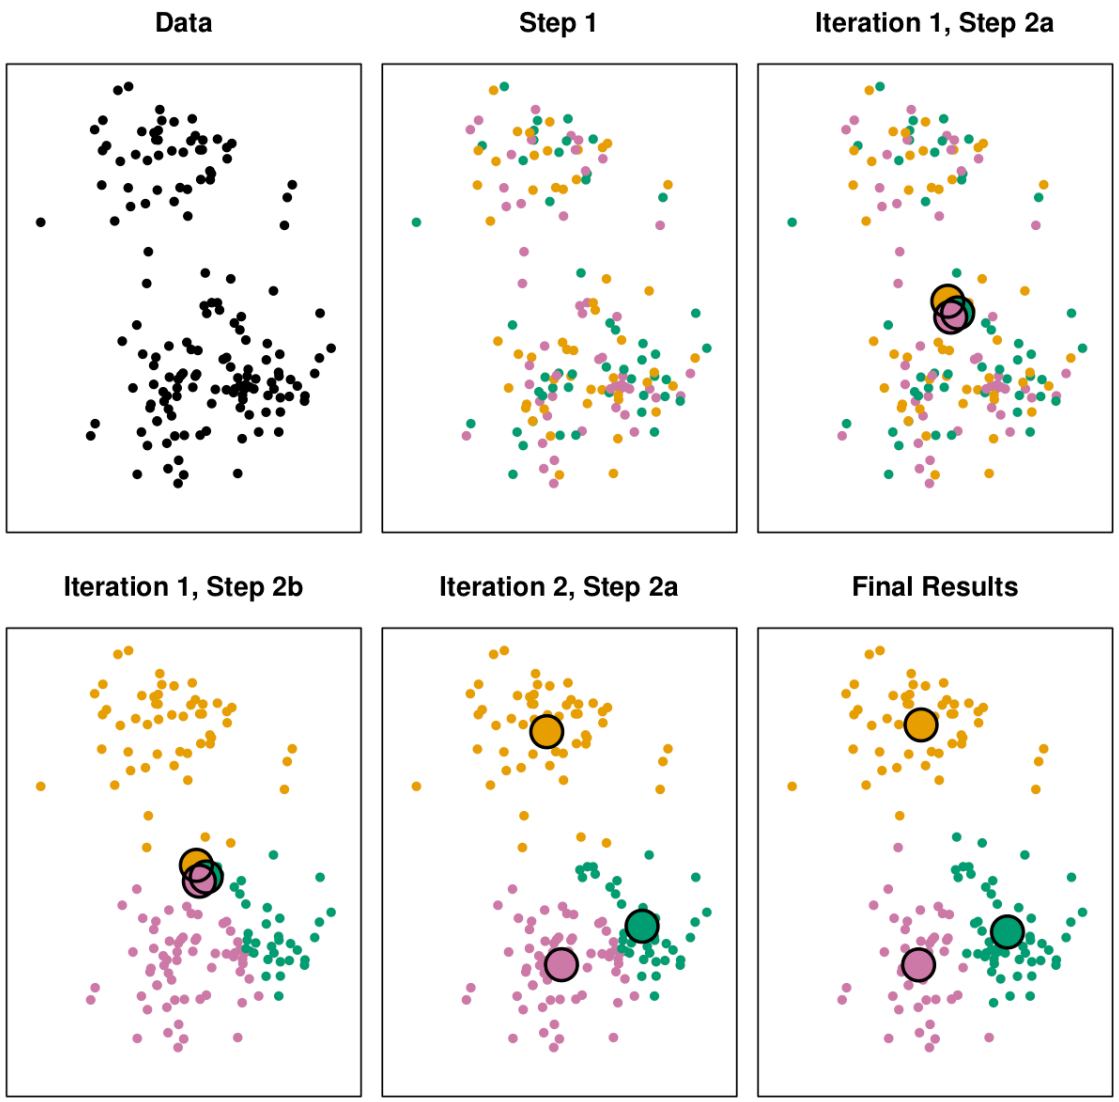

Характеристики алгоритма

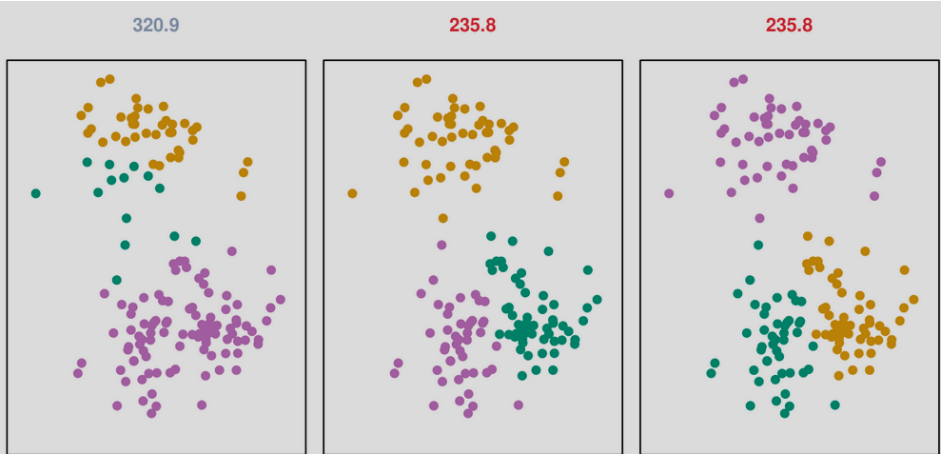

- Алгоритм является градиентным (descent algorithm) — он завершается, когда ни одна точка не может быть перемещена в другой кластер с улучшением критерия
- Каждая инициализация может привести к различному локальному минимуму
- На практике мы запускаем обучение множество раз с разных рандомных точек и выбираем ту, которая приводит к лучшей сходимости

Выбор оптимального числа кластеров K

K не определено, поэтому мы подбираем его с помощью метрик: запускаем алгоритм для $K = 2, 3, \ldots, K_{max}$ и выбираем K, оптимизирующий выбранную метрику.

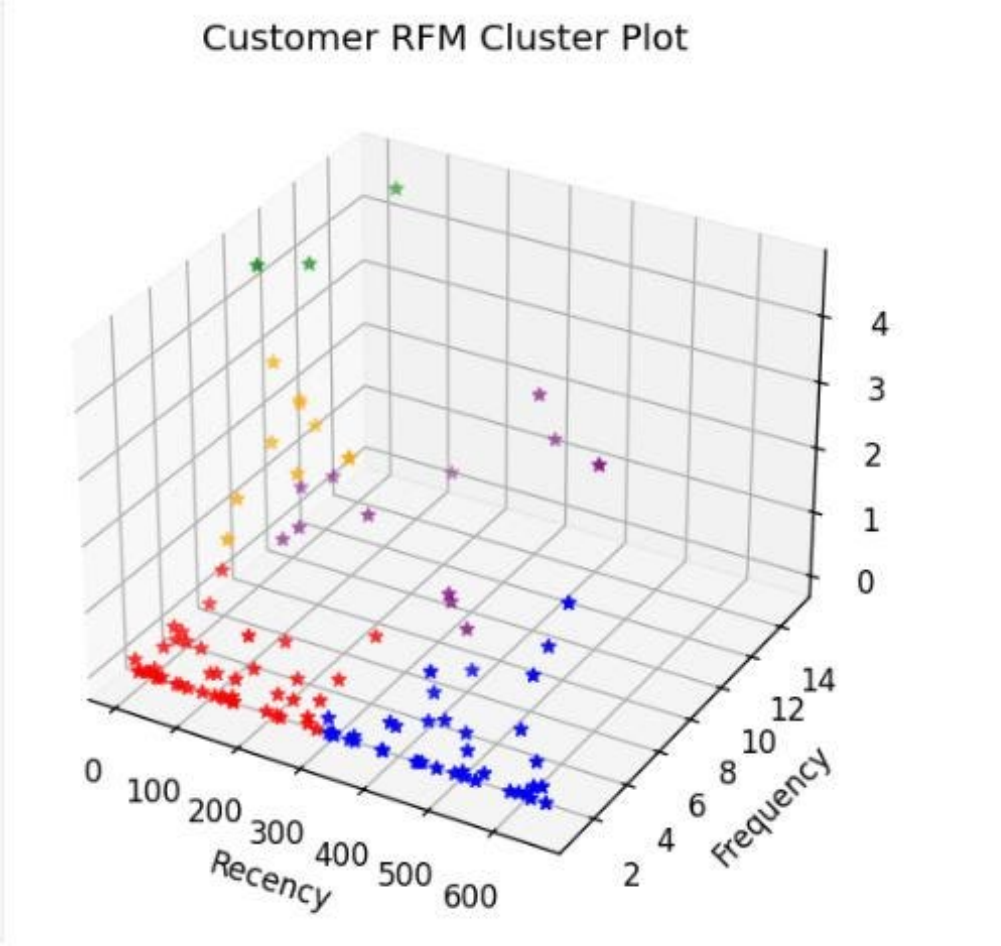

Elbow method (метод локтя)

Идея: с ростом K сумма внутрикластерных расстояний (WCSS) уменьшается. Оптимальный K находится в точке «излома» графика — дальше уменьшение замедляется.

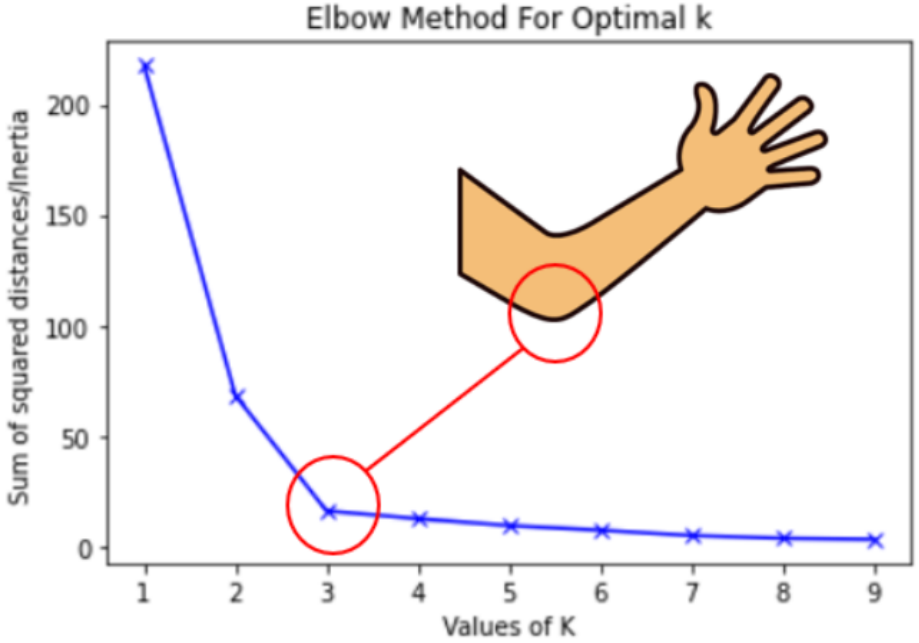

Line plot between K and inertia

Недостаток: субъективен, «локоть» может быть неявно выражен.

Silhouette score (коэффициент силуэта)

Оценивает, насколько объект похож на свой кластер по сравнению с соседними.

Для одного объекта:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

где:

- $a(i)$ — среднее расстояние до других объектов в своём кластере (компактность)
- $b(i)$ — среднее расстояние до объектов ближайшего соседнего кластера (отделимость)

Диапазон: $[-1, 1]$

- $s \approx 1$ — объект хорошо сгруппирован
- $s \approx 0$ — объект на границе между кластерами
- $s \approx -1$ — объект, вероятно, не в том кластере

Выбор K: максимизируем средний silhouette score по всем объектам.

Визуализация силуэта

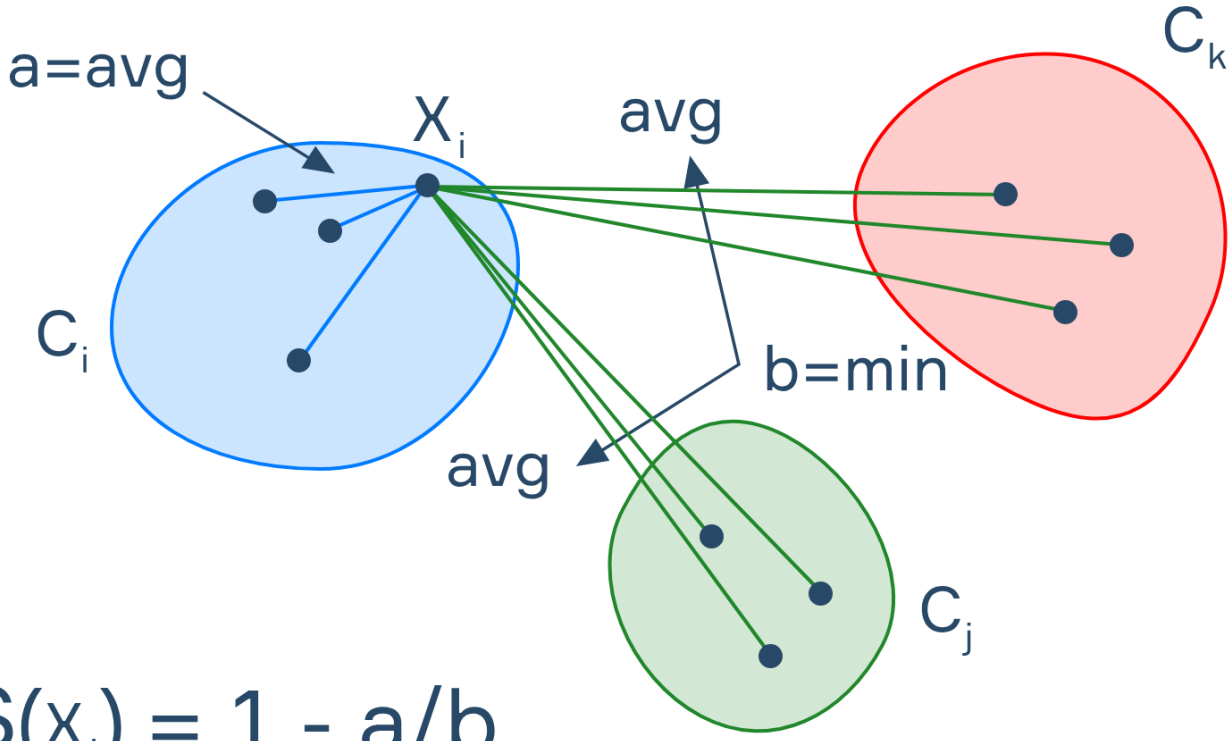

$$S(x_i) = 1 - a/b$$

Calinski–Harabasz index (индекс дисперсионного отношения)

$$\mathrm{CH} = \frac{\mathrm{tr}(B_K)}{\mathrm{tr}(W_K)} \cdot \frac{N-K}{K-1}$$

где:

- $\mathrm{tr}(B_K)$ — след межкластерной дисперсионной матрицы (разброс между кластерами)
- $\mathrm{tr}(W_K)$ — след внутрикластерной дисперсионной матрицы (разброс внутри кластеров)

Выбор K: максимизируем индекс CH.

Davies–Bouldin index

$$\mathrm{DB} = \frac{1}{K} \sum_{i=1}^{K} \max_{j \neq i} \left(\frac{\sigma_i + \sigma_j}{d(c_i, c_j)} \right)$$

где:

- σ_i — среднее расстояние от объектов кластера i до его центроида (разброс внутри)
- $d(c_i, c_j)$ — расстояние между центроидами кластеров i и j (разделимость)

Выбор K: минимизируем индекс DB.

Иерархические методы

Строят «дерево» (дендрограмму) вложенных кластеров.

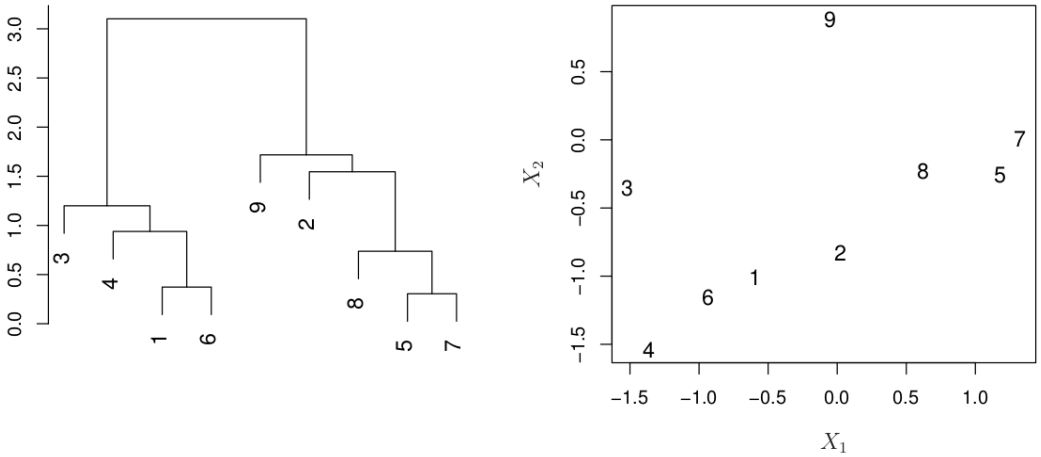

- **Агломеративные (снизу вверх):** каждая точка — отдельный кластер, затем они попарно сливаются
- **Дивизивные (сверху вниз):** все данные — один кластер, затем рекурсивно делятся

Применение: классификация биологических видов (филогенетика), анализ иерархии социальных групп.

Методы на основе анализа плотности распределения

Ищут области с высокой плотностью точек, разделенные областями с низкой плотностью. Позволяют находить кластеры произвольной формы и работать с шумом.

DBSCAN: формирует кластеры вокруг плотных окрестностей. Использует два параметра: радиус окрестности и минимальное число точек.

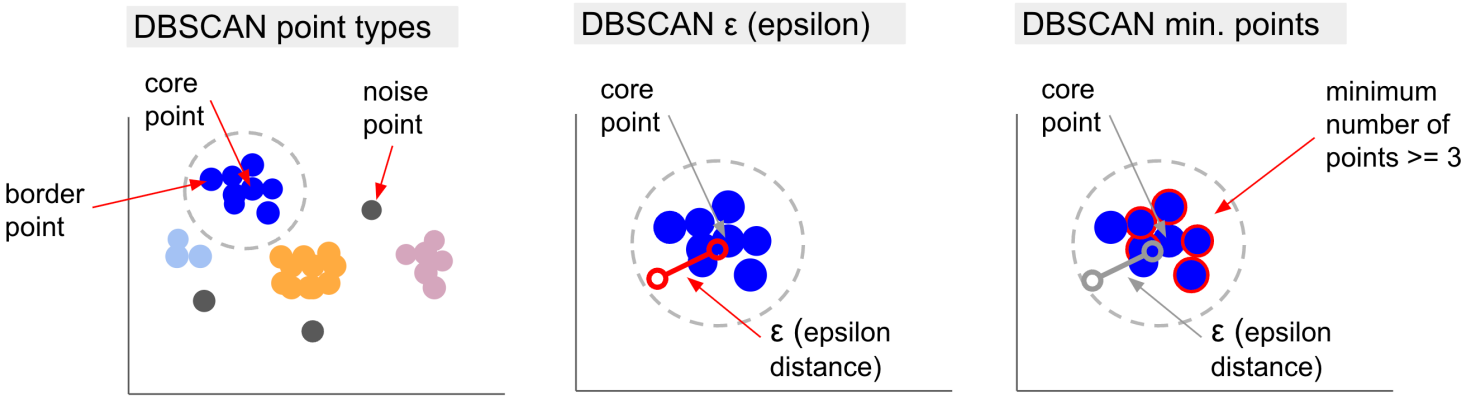

Что читать

- https://svgoudar.github.io/Learn-ML-and-NLP/machine_learning/supervised_learning/KNN/04_part.html
- https://web.stanford.edu/class/stats305c/lectures/Clustering.html
- https://trevorhastie.github.io/ISLR/
- https://link.springer.com/book/10.1007/978-0-387-84858-7
- https://link.springer.com/chapter/10.1007/978-0-387-84858-7_14
- https://link.springer.com/chapter/10.1007/978-0-387-84858-7_13
- https://portal.tpu.ru/SHARED/a/ALEXYEFREMOV/tutoring/Tab10/Lecture%204.pdf
- https://deepwiki.com/krishnaik06/Complete-Data-Science-With-Machine-Learning-And-NLP-2024/2.1.3-silhouette-clustering