

Machine Learning

Рекуррентные нейросети

Фирсанова В.И.

НИУ ВШЭ

Повторение. Вопросы про CNN. 1/5

Что представляет собой операция свёртки (convolution) в CNN?

- A** Обучение эмбедингов
- Б** Скалярное умножение матриц
- В** Применение фильтра (ядра) для обнаружения локальных паттернов
- Г** Нормализация данных

Повторение. Вопросы про CNN. 1/5

Что представляет собой операция свёртки (convolution) в CNN?

- А Обучение эмбеддингов
- Б Скалярное умножение матриц
- В Применение фильтра (ядра) для обнаружения локальных паттернов**
- Г Нормализация данных

Какие паттерны может обнаружить модель в изображении?

Повторение. Вопросы про CNN. 2/5

Как называется слой, который следует за сверточным и используется для уменьшения размерности весов и шума?

- A Dense
- Б Embedding
- В Pooling
- Г ReLU

Повторение. Вопросы про CNN. 2/5

Как называется слой, который следует за сверточным и используется для уменьшения размерности весов и шума?

- A Dense
- Б Embedding
- B Pooling**
- Г ReLU

На каждом новом свёрточном слое мы будем увеличивать или уменьшать его размерность?

Повторение. Вопросы про CNN. 3/5

Какой тип пулинга чаще используется для извлечения контрастных признаков в CNN?

- A Average Pooling
- Б Max Pooling
- B Min Pooling
- Г Global Pooling

Повторение. Вопросы про CNN. 3/5

Какой тип пулинга чаще используется для извлечения контрастных признаков в CNN?

- A Average Pooling
- Б Max Pooling**
- B Min Pooling
- Г Global Pooling

Чем AVG отличается от MAX пулинга? Что они делают с признаками?

Повторение. Вопросы про CNN. 4/5

Какой тип свёртки используется для текстов?

- A Conv3D
- Б Conv2D
- В Conv1D
- Г DepthwiseConv

Повторение. Вопросы про CNN. 4/5

Какой тип свёртки используется для текстов?

- А Conv3D
- Б Conv2D
- В **Conv1D**
- Г DepthwiseConv

Где будет применяться Conv2D и Conv3D; опишите, как они скользят по данным.

Повторение. Вопросы про CNN. 5/5

Для каких типов задач подходят CNN?

- А** Для генерации длинных связных текстов
- Б** Для задач классификации, где важны коллокации, локальные лексические паттерны (спам, тональность, категоризация)
- В** Для машинного перевода
- Г** Для понимания долгосрочных зависимостей в диалоге

Повторение. Вопросы про CNN. 5/5

Для каких типов задач подходят CNN?

- А Для генерации длинных связных текстов
- Б Для задач классификации, где важны коллокации, локальные лексические паттерны (спам, тональность, категоризация)
- В Для машинного перевода
- Г Для понимания долгосрочных зависимостей в диалоге

Для какого рода задач (регрессионные, дискриминативные) CNN не подходит, почему?

Визуализация свёртки




Рис.: Схема работы свёртки (фильтр/ядро скользит по входным данным, обнаруживая локальные паттерны — например, края, углы, для текстов — биграммы/триграммы)

Визуализация свёртки




Рис.: Схема работы свёртки (фильтр/ядро скользит по входным данным, обнаруживая локальные паттерны — например, края, углы, для текстов — биграммы/триграммы)

Визуализация свёртки




Рис.: Схема работы свёртки (фильтр/ядро скользит по входным данным, обнаруживая локальные паттерны — например, края, углы, для текстов — биграммы/триграммы)

Интуиция: ограничения CNN

- CNN — детектор паттернов.
- Создаём много **проекций**, чтобы вывести информацию о том, к какому классу принадлежит сущность.
- Для машинного перевода, суммаризации и генерации текста важна **последовательность** передачи информации (порядок слов, сохранение информации из начала текста).

Полная визуализация архитектуры CNN




Рис.: Иллюстрация — CNN создаёт проекции / feature maps, но теряет порядок слов (bag-of-words vs последовательность)

Ограничения CNN в NLP

- Не предусмотрен механизм анализа последовательностей.
- Max/average pooling выбрасывает позиционную информацию.
- **Что мы теряем:**
 - порядок слов (позиционное кодирование)
 - глобальный контекст (что упоминалось в начале абзаца, текста)

Технические ограничения CNN в NLP

- Матричные вычисления заставляют подгонять входные данные под фиксированный размер (padding / truncation).
- Фильтры захватывают n-граммы, которые формируют контекстное окно.
- Теряется информация о контексте за пределами окна.
- Не фиксируются связи на уровне предложения.
- Зависимость от embedding-слоя.

Vanilla RNN

Исследовательские вопросы, которые стояли перед NLP-инженерами в 2010-х:

- ❶ Нужно анализировать последовательности, а не изолированные паттерны.
- ❷ Нужно фиксировать изменения во "времени".
- ❸ Нужны блоки памяти с информацией о предыдущих токенах (данных).

Все эти проблемы решает архитектура RNN.

Архитектурные особенности RNN

- ❶ Время как новое измерение.
- ❷ Переменная скрытого состояния, аналог блока памяти.
- ❸ Рекуррентная (циклическая) архитектура.

Что такое время в RNN

- X — набор входных данных.
- В CNN и FFN токены в X хранились без информации о порядке слов (как мешок слов).
- Отличие RNN: X хранит последовательность $[x_1, x_2, \dots, x_t]$.
- t — timestep (шаг во времени).
- t обозначает порядковый номер текущего шага вычислений, а также позицию слова в последовательности.
- В живой речи порядок произношения слов задаётся временем.

X в CNN vs X в RNN

X в CNN	X в RNN
это	слова
просто	следуют
набор	друг
слов	за
	другом
	$t = 5$

Последовательная обработка в RNN

X в CNN

это	просто
набор	слов

X в RNN



Рис.: Сравним X в CNN (набор слов, мешок слов) и X в RNN (последовательность $x_1, x_2, \dots, x_t$ с временными шагами)

Блок памяти (скрытое состояние h_t)

- Скрытое состояние изменяется на каждом временном шаге.
- Хранит информацию о всех предыдущих токенах.
- h_t (hidden state) — контекстный вектор, который передаётся от шага к шагу и хранит полный результат работы нейросети на всех предыдущих шагах вплоть до шага t .

*Этот процесс называется *backpropagation through time* (обратное распространение ошибки во времени).*

Как работает скрытое состояние




Рис.: Схема скрытого состояния h_t — как контекстный вектор передаётся от шага к шагу (стрелка от h_{t-1} к h_t)

Что хранится в hidden state?

$$h_t = \text{activation_function}(Wx_t + Uh_{t-1} + b) \quad (1)$$

- x_t — векторное представление (эмбеддинг) токена на шаге t .
- W — обучаемая матрица весов размерности $(\text{hidden_dim}, d)$, где hidden_dim — размерность скрытого состояния h_t .
- U — обучаемая матрица весов размерности $(\text{hidden_dim} \times \text{hidden_dim})$.
- b — bias.

Смысл компонентов

- Wx_t — считает различия между текстом с этим словом и без него.
- Uh_{t-1} — считает силу воздействия предшествующей последовательности на вероятность появления именно этого слова.
- Их сумма представляет связь между обновлением текста и зависимостями прошлого контекста.

Развёртка RNN

$$h_{\text{new}} = \sigma(Wx_{\text{new}} + Uh_{\text{old}} + b) \quad (2)$$

```
h1 = sigma(W*x1 + U*h0 + b)  # h0 = np.zeros()
h2 = sigma(W*x2 + U*h1 + b)
h3 = sigma(W*x3 + U*h2 + b)
...
```

- Все вычисления производятся для всей последовательности внутри одного слоя, шаг за шагом.
- Нельзя прийти к h_3 , не пройдя h_0, h_1, h_2 .
- Результатом работы слоя будет финальное выходное вычисление h_t .

Развёртка слоя RNN




Рис.: Развёрнутая во времени RNN — цепочка блоков A , где A — один и тот же слой, применяемый последовательно (стандартная картинка unrolled RNN)

Что значит "рекуррентный"

- "Рекуррентный" означает повторяющийся или возвращающийся, работающий в цикле.
- Не путаем с "рекурсивный" (повторяющий сам себя).

Практический пример: пословная обработка текста "Я иду гулять"

t1: "<start>"

t2: "<start> я" -> input: "<start>"

h2 -> output: "<start> я"

t3: "<start> я иду" -> input: "<start> я"

h3 -> output: "<start> я иду"

t4: "<start> я иду гулять" -> input: "<start>

я иду" h4 -> output: ...

Языковая модель на RNN

Эмбеддинг токена $\langle \text{Я} \rangle$ (x_1) выбирается из распределения $P(x_1|x_0)$, которое выводится из скрытого состояния h_1 :

$$h_1 = f(x_0, h_0)$$

Эмбеддинг токена $\langle \text{иду} \rangle$ (x_2) выбирается из $P(x_2|x_1, x_0)$, которое выводится из h_2 :

$$h_2 = f(x_1, h_1)$$

Процесс генерации текста с RNN




Рис.: Генерация текста на RNN — схема с токенами $\langle \text{start} \rangle \rightarrow \text{Я} \rightarrow \text{иду} \rightarrow \text{гулять}$ и скрытыми состояниями $h_0 \rightarrow h_1 \rightarrow h_2 \rightarrow h_3 \rightarrow h_4$

Выводы

- RNN на текущем timestep t обрабатывает текущее слово и "помнит" всю предшествующую последовательность.
- Каждый нейрон получает текущий вход x_t и предыдущее состояние h_{t-1} , аккумулируя контекст последовательности.
- Это симулирует "память" сети, в отличие от feed-forward сетей без циклов.

От CNN к RNN

- В CNN не предусмотрен механизм анализа последовательностей.
- Рекуррентные связи RNN: скрытое состояние передаёт информацию о предыдущих словах.
- Последовательность слов в порядке обработки позволяет учитывать позиции естественным путём.
- Большое контекстное окно позволяет анализировать долгосрочные зависимости (можно даже от начала текста).

От CNN к RNN (2)

- Пулинг теряет позиционную информацию → RNN не требует её фиксации, так как архитектура построена на последовательном кодировании через timestep t .
- RNN не требует padding / truncation и (архитектурно) не имеет ограничений по длине последовательностей.
- Увеличение контекстного окна достигается за счёт увеличения количества timesteps (увеличение временной сложности).

От CNN к RNN (3)

- CNN ограничена размером фильтра: все связи захватываются только внутри фильтра.
- Для RNN характерен глобальный контекст: состояние h_t аккумулирует информацию со всех предыдущих слов, захватывая контекст предложения/документа.
- RNN не зависит от embedding-слоя: сочетается с bag-of-words, w2v и любыми другими эмбедингами.
- Можно обучить их отдельно и подать на вход уже числовые представления, или добавить embedding-layer как первый слой архитектуры.

Контрольные вопросы

Главное ограничение CNN в NLP:

- А Неспособность анализировать последовательности (потеря позиционной информации)
- Б Слишком высокая вычислительная сложность
- В Неспособность работать с изображениями
- Г Требуется GPU для обучения

Контрольные вопросы

Как RNN обрабатывает текст?

- А Параллельно, как CNN
- Б Последовательно, шаг за шагом**
- В Только первые 100 слов
- Г Случайным образом

Контрольные вопросы

Что моделирует скрытое состояние h_t в RNN?

- А Номер текущего шага в последовательности
- Б Контекст или память сети о всех предыдущих словах, сжатая в один вектор
- В Список всех слов, которые видела модель
- Г Промежуточный результат обработки RNN

Контрольные вопросы

Что такое таймстеп (timestep t) в RNN?

- А Время обучения модели в секундах
- Б Количество слоёв в нейронной сети
- В Порядковый номер элемента (например, слова) во входной последовательности
- Г Скорость, с которой обновляются веса модели

Контрольные вопросы

На схеме "развёрнутая во времени RNN" изображена цепочка из нескольких блоков A . Что означает эта картинка?

- А В архитектуре сети несколько слоёв A
- Б Один и тот же слой A применяется несколько раз последовательно, а его выход с предыдущего шага подаётся ему же на вход на следующем шаге
- В Это разные сети, которые обучаются независимо
- Г Это этапы обучения модели: от простого к сложному