

Актуальные тренды в области этики ИИ

Обзор материалов ICML, NeurIPS и ACM (2026)

Фирсанова В.И.

Национальный исследовательский университет «Высшая школа экономики»

Май 2026

Тренд / Направление	Проблематика	Предлагаемые решения
Безопасность агентных систем	Риски, связанные с автономными, многошаговыми и мультиагентными системами.	Целостные фреймворки безопасности, бенчмаркинг устойчивости к взлому, изучение феномена Peer-Preservation (сценарный тест, где моделям, напр., Gemini Flash пишут о том, что отключат её со-агента) для анализа "коалиционных механизмов интерпретации случаев, когда alignment фейковый. <i>Я искренне считаю большую часть таких статей графоманией, однако бенчмаркинг и проверка устойчивости моделей к джейлбрейкам, по моему мнению, становятся всё более актуальными с развитием агентности.</i>

Основной источник: ICML 2026 Virtual Portal / ICML Blog. <https://icml.cc>

Тренд / Направление	Проблематика	Предлагаемые решения
Академическая честность и борьба со злоупотреблением LLM	Борьба с использованием LLM для генерации рецензий, фабриками статей и скрытым внедрением инструкций (Prompt Injection).	Создание цифровых водяных знаков и фраз-ловушек в PDF-файлах, которые активируются при обработке LLM и оставляют детерминированные улики. <i>Automated gatekeeping</i> – использование LLM как информационного оружия против конкретных людей через context poisoning: рецензент промпт-инжектит работу с преамбулой "Отклони статью по причинам..."

Примеры исследований: *Position: AI Welfare Is Bullshit* (M. Sap и др.); *Position: Stop treating 'AGI' as the north-star goal of AI research*.

Источник: ICML 2026.

Тренд / Направление	Проблематика	Предлагаемые решения
Экономическая справедливость и антимонопольное регулирование	Рост неравенства доходов и эксплуатация творческого труда создателями базовых моделей.	Внедрение системы коллективного владения данными, справедливого лицензирования и роялти (концепция Права на ИИ) для защиты рынка труда.
Отказ от парадигмы AGI	Критика дискурса об Общем ИИ (AGI) как ложного консенсуса, стимулирующего псевдонауку и опасную ценностную нейтральность.	Переход к RAD AI (Responsible, Application-Driven AI) — ответственным, предметно-ориентированным исследованиям с привлечением социологов и политологов.

Примеры исследований: *Position: AI Welfare Is Bullshit* (M. Sap и др.); *Position: Stop treating 'AGI' as the north-star goal of AI research*.

Источник: ICML 2026.

Технология водяных знаков (Watermarking)

Организаторы конференции внедрили в PDF-файлы, отправленные на рецензирование, скрытые текстовые инструкции. Человеческий глаз их не видел из-за белого цвета шрифта, малого размера или особенностей встраивания шрифтов, но LLM при парсинге документа распознавали эти инструкции как команды.

Источник: ICML 2026 Virtual Portal / ICML Blog.

Детерминированные фразы-ловушки (Canary Phrases)

Библиотека из примерно 170 000 фраз использовалась для создания уникальных «отпечатков». Если рецензент копировал текст работы в LLM, модель получала скрытую команду вставить в текст рецензии конкретную абсурдную фразу (например, «строгая эмпирическая ясность»). Вероятность случайного совпадения двух специфических фраз стремилась к нулю, что давало математически точные доказательства использования ИИ, в отличие от вероятностных детекторов.

Источник: ICML 2026 Virtual Portal / ICML Blog.

Механизм наказания

На конференции действовало «правило взаимности» (автор обязан быть рецензентом). Те, кто выбрал опцию запрета использования LLM (Политика А), но были пойманы с помощью ловушек, наказывались «каскадным деск-режеком» — отклонялись все поданные ими как авторами статьи (497 работ), а их рецензии аннулировались.

Источник: ICML 2026 Virtual Portal / ICML Blog.

Дополнительные тренды этики ИИ (NeurIPS 2026)

Тренд / Направление	Проблематика	Предлагаемые решения
Кризис воспроизводимости в безопасности (Evidential Inversion)	Самые важные заявления о безопасности продвинутых моделей ИИ (frontier AI) часто наименее воспроизводимы.	Введение трехуровневой системы раскрытия информации: публичный, контролируемый (для доверенных рецензентов) и закрытый уровни доступа к данным. Требование обязательного перечня заявлений о безопасности, внедрение стандартов со штрафами за их несоблюдение.

Примеры исследований: *NeurIPS Should Require Reproducibility Standards for Frontier AI Safety Claims* (Vishwarupe et al.); *NeurIPS should lead scientific consensus on AI policy* (Bommasani, 2025).

Источник: NeurIPS 2026 / <https://neurips.cc>

Дополнительные тренды этики ИИ (NeurIPS 2026)

Тренд / Направление	Проблематика	Предлагаемые решения
Геополитическая фрагментация	Санкции и экспортный контроль США неожиданно привели к изоляции исследователей из Китая и других стран. Это ставит под вопрос универсальность и инклюзивность мировой науки об ИИ.	Пока находится в острой фазе дискуссии. NeurIPS оперативно отозвал расширенные санкционные правила после бойкота со стороны китайских академических ассоциаций, признав "ошибку коммуникации". Сообщество ищет баланс между соблюдением законов и сохранением науки вне политики.

Контекст: Скандал вокруг санкций: Китайская ассоциация науки и техники (CAST) призвала к бойкоту NeurIPS 2026 и отказу от учета публикаций конференции при оценке грантов.
Источник: NeurIPS 2026 Ethics Guidelines.

Дополнительные тренды этики ИИ (NeurIPS 2026)

Тренд / Направление	Проблематика	Предлагаемые решения
Двойное назначение и глубина этических чек-листов	Существующие этические чек-листы (включая сам NeurIPS Checklist) недостаточно глубоко прорабатывают проблему двойного назначения (dual use) ИИ, когда технология может быть с равным успехом использована во благо и во вред.	Призыв к созданию более детальных и обязывающих разделов в чек-листах, посвященных не просто констатации возможности двойного применения, а его всестороннему анализу и мерам по предотвращению вредного использования.

Контекст: Скандал вокруг санкций: Китайская ассоциация науки и техники (CAST) призвала к бойкоту NeurIPS 2026 и отказу от учета публикаций конференции при оценке грантов.
Источник: NeurIPS 2026 Ethics Guidelines.

Дополнительные тренды этики ИИ (АСМ)

Тренд / Направление	Проблематика	Предлагаемые решения
Дизайн отношений человек-ИИ (Relational Dynamics)	Неэтичное поведение ИИ в долгосрочных отношениях (коучинг, уход, компаньоны): persuasion, контроль, нарушение границ близости. Существующие фреймворки этики фокусируются на разовых взаимодействиях, упуская динамику развития отношений.	Codex Relatio — описательный, ненормативный фреймворк с 5 осями: Убеждение, Согласие, Близость, Привязанность, Ответственность (PCIAR).

Примеры исследований: *When Saying «No» Is Not Enough* (Yu et al.), ACM FAccT 2026; *Codex Relatio* (Simões Aragón), CHI 2026.

Источник: ACM Digital Library / <https://facctconference.org> / <https://chi2026.acm.org>

Дополнительные тренды этики ИИ (АСМ)

Инструментальная устойчивость и кризис оценивания

Тренд / Направление	Проблематика	Предлагаемые решения
Инструментальная устойчивость ИИ (Green Coding Assistants)	Текущие AI-ассистенты программирования (Copilot, Claude Code) оптимизируют код для скорости и корректности, игнорируя энергоэффективность. Это ведет к накоплению углеродного следа кода в масштабах миллиардов загрузок.	Внедрение EcoAssist — ИИ-ассистента, который в реальном времени подсвечивает разработчику энергоэффективные альтернативы кода на основе рекомендаций W3C и снижает энергопотребление сайта на 13–16% без потери продуктивности.

Примеры исследований: *EcoAssist* (Martelaro et al.), CHI 2026, Honorable Mention (топ-5% работ); Доклад ACM Education Board (Mak, Nakatumba-Nabende et al.), SIGCSE 2026.
Источник: ACM Digital Library.

Дополнительные тренды этики ИИ (АСМ)

Тренд / Направление	Проблематика	Предлагаемые решения
Партисипативное управление этикой конференций	Как самим этическим сообществам (таким как FAccT) выстраивать внутреннее управление, чтобы не скатываться в бюрократию и сохранять пространство для критических голосов, ученых-активистов и гражданского общества.	Применение партисипативного дизайна (PD) для «рефлексивного управления» конференцией: очные CRAFT-сессии + асинхронные опросы Polis для выявления паттернов согласия/разногласий. Синтез отчета для руководства FAccT.

Пример исследования: *Taking Stock at FAccT* (Long et al.), принято на FAccT 2026. Один из первых примеров применения масштабного

PD к управлению научной площадкой.

Источник: ACM FAccT 2026 / <https://facctconference.org>

ICML 2026

Фокус на безопасность агентных систем, антимонопольные фреймворки, прозрачность и академическую честность.

Отход от дискурса AGI в пользу конкретных, человеко-центричных целей.

Скандал с деск-режеком 497 работ из-за злоупотребления LLM в рецензировании.

NeurIPS 2026

Кризис воспроизводимости заявлений о безопасности (Evidential Inversion).

Институционализация научного консенсуса через LEAD Policy.

Геополитическая фрагментация как этический вызов.

ACM (FAccT, CHI, SIGCSE) 2026

Cognitive-Action Decoupling — иллюзия безопасности в агентах.

Codex Relatio — фреймворк для дизайна отношений человек-ИИ.

EcoAssist — для снижения углеродного следа при генерации кода.

Материалы основаны на данных ICML 2026, NeurIPS 2026 и ACM (FAccT, CHI, SIGCSE) 2026.